Симетрична криптографія

Лекція 5

Основні поняття математичної теорії інформації
Надлишковість на символ джерела

5.1. Ймовірнісний ансамбль і ентропія.

Нехай $X = \{x_1, x_2, ..., x_n\}$ – скінченна множина, на якій заданий розподіл ймовірностей

$$P = \{p(x_1), p(x_2), ..., p(x_n)\},\ p(x_i) = p_i \geq 0,\ \sum_{i=1}^{n} p_i = 1.$$

Пара (X, P) в теорії інформації є основним математичним об'єктом, основною математичною структурою, властивості якої дозволяють її використовувати для моделювання і дослідження практично важливих задач в дуже різних галузях і областях. Елементи x_i в практичних застосуваннях можуть бути, наприклад, якимись подіями, символами, сигналами, числами, повідомленнями, шифрованими текстами, фізичними об'єктами тощо.

Означення 5.1. Ймовірнісним ансамблем називається довільна скінчена множина з ймовірнісною мірою

$$(X, P),\ X = \{x_1, x_2, ..., x_n\},\ P = \{p(x_1), p(x_2), ..., p(x_n)\},$$

$$p(x_i) = p_i \geq 0,\ \sum_{i=1}^{n} p_i = 1. \qquad (5.1)$$

В теорії кодування і передачі інформації часто для ймовірнісного ансамблю використовують такий запис

$$\left\| \begin{matrix} X \\ P \end{matrix} \right\| = \left\| \begin{matrix} x_1\ x_2 ... x_n \\ p_1\ p_2 ... p_n \end{matrix} \right\|$$

і називають дискретним джерелом інформації або скінченною схемою.

Інтуїтивно зрозуміло, що повідомлення з малоймовірним змістом несе у собі більше інформації, ніж більш імовірне, якщо ж різні повідомлення незалежні, то спільна інформація дорівнює сумі в кожному повідомленні. Інтуїція підказує також, що чим більше інформації тим більше місця потрібно для її запису в деякій системі кодування і більше кроків для

знаходження необхідної інформації. Клод Шеннон запропонував і дослідив для виміру кількості інформації функцію, яка відповідає цьому інтуїтивному уявленню, і до того ж є зручною при обчисленнях.

Означення 5.2. *Власною інформацією повідомлення* x_i називається величина

$$I(x_i) = -\log p(x_i) \geq 0 .$$

Усереднимо власну інформацію за всіма повідомленнями ансамблю (5.1)

$$H(X) = -\sum_{i=1}^{n} p(x_i) \log p(x_i) \qquad (5.2)$$

Означення 5.3. Величина $H(X)$, яка для ансамблю (5.1) визначається формулою (5.2) називається *ентропією ймовірнісного ансамблю* (*X*,*P*). Також використовується термін *невизначеність ансамблю.*

H(*X*) може бути інтерпретована як невизначеність експерименту, в якому з ансамблю *X* вибирається одне повідомлення, причому повідомлення x_i може бути вибране з ймовірністю $p(x_i)$, $i = 1, 2, ...n$. Найчастіше в означенні ентропії беруть логарифм за основою 2, тоді інформація та ентропія вимірюються в бітах. Якщо логарифм десятковий (lg), то – в дитах, якщо логарифм натуральний (ln), то – в натах.

Властивості ентропії.

Сформулюємо перші властивості ентропії (5.2) ймовірнісного ансамблю (5.1).

1) $H(X) \geq 0$, оскільки $p_i \geq 0$ і $\log \frac{1}{p_i} \geq 0$, причому $0 \times \log 0$ не визначено, та оскільки згідно з правилом Лопиталя $p \cdot \log p \xrightarrow[p \to 0]{} 0$, то за неперервністю такі доданки в (5.2) вважаються як нульові.

2) $H(X) = 0$ тоді і тільки тоді, коли деяке $p_i = 1$, а всі інші $p_j = 0, j \neq i$.

3) $H(\mathrm{X}) \leq \log n$. Нерівність випливає з нерівності Йєнсена для випуклої вгору функції $\sum_{i=1}^{n} p_i f(x_i) \leq f(\sum_{i=1}^{n} p_i x_i)$.

4) $H(\mathrm{X})$, $X = \{x_1, x_2, ..., x_n\}$, приймає максимальне значення тоді, коли всі x_i, є рівноймовірними: $p(x_i) = \frac{1}{n}$. В цьому випадку

$$H(X) = -\sum_{i=1}^{n} \tfrac{1}{n} \log \frac{1}{n} = \log n .$$

Приклад 5.1. Розглянемо ансамбль з двох елементів і побудуємо графік залежності ентропії від ймовірності p_1.

$$\left\| \begin{matrix} X \\ P \end{matrix} \right\| = \left\| \begin{matrix} x_1 & x_2 \\ p_1 & p_2 \end{matrix} \right\|$$

$H(\mathrm{X}) = -p_1 \log p_1 - p_2 \log p_2$

Ентропія двоточкової випадкової величини.

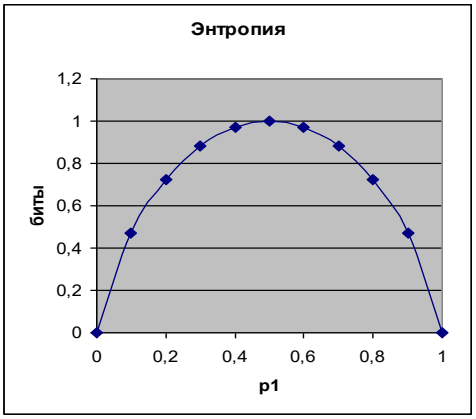

5.2. Сукупна ентропія двох ймовірнісних ансамблів.

Сумісні ансамблі. Розглянемо декартовий добуток $X \times Y$ скінченних множин $X = \{x_1, x_2, ..., x_n\}$ та $Y = \{y_1, y_2, ..., y_m\}$, тобто множину пар $\{(x, y),\ x \in X,\ y \in Y\}$. Нехай на множині пар задано розподіл ймовірностей $p(x, y)$, $\sum_{x \in X, y \in Y} p(x, y) = 1$. Множину $X \times Y = \{(x, y), x \in X, y \in Y\}$ з ймовірностями $p(x, y)$ можна розглядати як ймовірнісний ансамбль. Розподіл $p(x, y)$ індукує розподіли на X та Y:

$$p(x) = \sum_{y \in Y} p(x, y); \qquad p(y) = \sum_{x \in X} p(x, y),$$

тобто X та Y можна також розглядати як окремі ансамблі. Тоді говорять, що ансамблі X та Y *задані сумісно або сукупно*.

С іншого боку, нехай (X, P), (Y, Q) ймовірнісні ансамблі, $X = \{x_1, x_2, ..., x_n\}$, $P(x_i) = p_i$, $Y = \{y_1, y_2, ..., y_m\}$, $P(y_j) = q_j$. Також задано ймовірність кожної пари $P(x_i, y_j) = p_{ij} \geq 0$ і виконуються умови узгодженості:

$$\sum_{i,j} p_{ij} = 1,\ \sum_{i=1}^{n} p_{ij} = q_j,\ \sum_{j=1}^{m} p_{ij} = p_i. \qquad (5.3)$$

Тоді ансамблі X та Y *задані сумісно або сукупно*. Сумісний ансамбль можна записати у вигляді $(X \times Y, P * Q)$ з сумісним розподілом $P * Q = \{P(x_i, y_j) = p_{ij} \geq 0,\ i = \overline{1,n},\ j = \overline{1,m}\}$ (5.3).

Означення 5.4. *Сукупною ентропією* ансамблів X та Y, тобто ентропією ансамблю $(X \times Y, P * Q)$, у відповідності з загальним означенням (5.2) буде величина

$$H(XY) = -\sum_{(x,y) \in X \times Y} p(x, y) \log p(x, y), \qquad (5.4)$$

або $H(X,Y)=H(XY)=-\sum_{i=1}^{n}\sum_{j=1}^{m}p_{ij}\log p_{ij}$.

Означення 5.5. Сумісно задані ансамблі X та Y з розподілами (5.3) називаються *незалежними*, якщо $\forall(x,y): p(x,y)=p(x)p(y)$, або в інших позначеннях $p_{ij}=p_i\cdot q_j \quad \forall i=\overline{1,n}, \quad j=\overline{1,m}.$

Твердження 5.1. Якщо ансамблі X та Y – незалежні , то

$$H(XY)=H(X)+H(Y).$$

Доведення.

$$H(X,Y)=-\sum_{i,j}p_{ij}\log p_{ij}=-\sum_{i,j}p_iq_j\log p_iq_j=-\sum_{i,j}p_iq_j\log p_i-\sum_{i,j}p_iq_j\log q_j=$$

$$=-\sum_{i=1}^{n}\sum_{j=1}^{m}p_iq_j\log p_i-\sum_{j=1}^{m}\sum_{i=1}^{n}p_iq_j\log q_j=-\sum_{i=1}^{n}p_i\log p_i\sum_{j=1}^{m}q_j-\sum_{j=1}^{m}q_j\log q_j\sum_{i=1}^{n}p_i=$$

$$=-\sum_{i=1}^{n}p_i\log p_i-\sum_{j=1}^{m}q_j\log q_j=H(X)+H(Y)$$

5.3. Умовна ентропія.

З курсу теорії ймовірностей відомо визначення *умовної ймовірності*:

$$p(x|y)=\frac{p(x,y)}{p(y)}, \quad p(y)\neq 0.$$

Нехай ансамблі X та Y задані сумісно і відомий результат експерименту над ансамлем Y: реалізовано елемент (повідомлення) y. Тоді, оскільки ансамблі задано сумісно, то елемент y, як подія, що відбулася, міняє ймовірність $p(x)$ кожної події $x\in X$ на умовну ймовірність $p(x\,|\,y)$. Умовна ентропія згідно з новим ймовірнісним розподілом на ансамблі X при умові y (як і в означенні ентропії (5.2)) визначаться за формулою:

$$H(X|y)=-\sum_{x\in X}p(x|y)\log p(x|y)$$

Усереднивши $H(X/y)$ за всіма y, отримаємо за означенням *умовну ентропію* ансамблю X відносно ансамблю Y.

Означення 5.6. *Умовною ентропію* ансамблю X відносно ансамблю Y називається величина

$$H\left(X|Y\right)=-\sum_{y\in Y}p(y)\sum_{x\in X}p\left(x|y\right)\cdot\log p\left(x|y\right)=$$

$$=-\sum_{\substack{x\in X\\ y\in Y}}p(x,y)\log p\left(x|y\right)=-\sum_{i,j}p_{ij}\log\frac{p_{ij}}{q_j} \tag{5.5}$$

Властивості умовної ентропії.

Твердження 5.2. Якщо ансамблі X та Y – незалежні, то

$$H(X\,|\,Y)=H(X)\,.$$

Доведення.

$$H(X\,|\,Y)=-\sum_{j=1}^{m}P(y_j)\sum_{i=1}^{n}P(x_i\,|\,y_j)\log P(x_i\,|\,y_j)=$$

$$=-\sum_{j=1}^{m}q_j\sum_{i=1}^{n}p_i\log p_i=\sum_{j=1}^{m}q_jH(X)=H(X)$$

Твердження 5.3. Для будь-яких ймовірнісних ансамблів X, Y виконуються нерівності

$$0\le H(X\,|\,Y)\le H(X)\le\log n\,.$$

Доведення. Оцінимо різницю

$$H(X\,|\,Y)-H(X)=-\sum_{i,j}p_{ij}\log\frac{p_{ij}}{q_j}+\sum_{i=1}^{n}p_i\log p_i=$$

$$=-\sum_{i=1}^{n}\sum_{j=1}^{m}p_{ij}\log\frac{p_{ij}}{q_j}+\sum_{i=1}^{n}\sum_{j=1}^{m}p_{ij}\log p_i=$$

$$=\sum_{i=1}^{n}\sum_{j=1}^{m}p_{ij}(\log\frac{q_j}{p_{ij}}+\log p_i)=\sum_{i=1}^{n}\sum_{j=1}^{m}p_{ij}\log\frac{q_jp_i}{p_{ij}}.$$

Далі використовуємо нерівність Йєнсена $\sum_{i=1}^{n}p_if(x_i)\le f(\sum_{i=1}^{n}p_ix_i)$ для випуклої вгору функції, в якої рівність тоді і тільки тоді, коли $x_i=a=\text{const}\ \forall i$. Покладемо $f(x)=\log x$.

$$\sum_{i=1}^{n}\sum_{j=1}^{m} p_{ij}\log\frac{q_j p_i}{p_{ij}} \le \log(\sum_{i=1}^{n}\sum_{j=1}^{m} p_{ij}\frac{q_j p_i}{p_{ij}}) = \log(\sum_{i=1}^{n}\sum_{j=1}^{m} q_j p_i) =$$

$$= \log(\sum_{i=1}^{n} p_i \sum_{j=1}^{m} q_j) = \log(\sum_{i=1}^{n} p_i) = \log 1 = 0.$$

Отримали нерівність $H(X\,|\,Y) - H(X) \le 0,$ яка разом з раніше розглянутими нерівностями доводить твердження 5.3.

Твердження 5.4. Для сукупної ентропії виконуються співвідношення

$$H(XY) = H(X) + H(Y\,|\,X) = H(Y) + H(X\,|\,Y)$$

Пояснення. Сукупна невизначеність експериментів X та Y дорівнює сумі ентропії X і ентропії, що залишилася після того, як результат експерименту X став відомим. X та Y входять у формулу симетрично.

Ще властивості умовної ентропії:

1) Виконується послідовність нерівностей:

$$H(X) \ge H(X\,|\,Y) \ge H(X\,|\,YZ)\ldots,$$

пояснення: додаткові знання не можуть збільшити невизначеність;

2) $H(XY\,|\,Z) = H(Y\,|\,Z) + H(X\,|\,YZ);$

3) $H(X,Y,Z) = H(X) + H(Y\,|\,X) + H(Z\,|\,X,Y).$

5.4. Взаємна інформація ансамблів *X* та *У*.

Означення 5.7. *Взаємною інформацією* ансамблів X та $У$ називається величина

$$I(X,Y) = H(X) - H(X\,/\,Y) = H(Y) - H(Y\,/\,X).$$

Властивості інформації.

Твердження 5.5. Для взаємної інформації виконуються нерівності

$$0 \le I(X,Y) \le \min\{\,H(X), H(Y)\}$$

Доведення. $I(X,Y)=H(X)-H(X\,|\,Y)=H(Y)-H(Y\,|\,X)$, а за твердженням 5.3 маємо нерівність $0\le H(X\,|\,Y)\le H(X)$. Тому виконуються обидві нерівності в твердженні 5.5.

Твердження 5.6. При незалежних ансамблях X та Y взаємна інформація

$$I(X;Y)=0.$$

Доведення *безпосередньо* випливає з твердження 5.2.

Ілюстрація властивостей ентропії і інформації за допомогою діаграм Венна з використанням множин *X, Y, Z*.

Порівняння ентропії з потужністю множин.

$H(X)\leftrightarrow|X|$

$H(Y)\leftrightarrow|Y|$

$H(Z)\leftrightarrow|Z|$

$H(X,Y)\leftrightarrow|X\cup Y|$

$H(X\,|\,Y)\leftrightarrow|X\setminus Y|$

$H(Y\,|\,X)\leftrightarrow|Y\setminus X|$

$I(X,Y)\leftrightarrow|X\cap Y|$

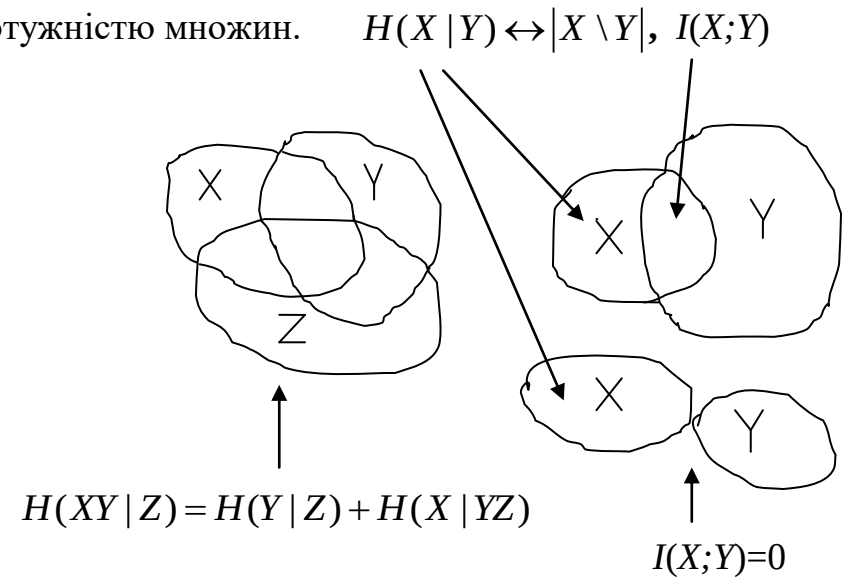

5.5. Ентропія на символ джерела. Моделі відкритого тексту.

Ентропією на символ джерела

Декартовий добуток позначимо $X_1\times X_2\times\ldots\times X_n=X^n$, якщо всі $X_i=X$. Якщо Z_m – алфавіт, то n-грама $(z_1,\ldots,z_n)\in Z_m^n$ і n ансамблів задані сукупно розподілом n-грам $P(x_1=z_1,\ldots,x_n=z_n)$ (вважаємо джерело стаціонарним: немає залежності від розташування n-грами в тексті). Ентропія n-грами за означенням ентропії ймовірнісного ансамблю (Z_m^n,P)

$$H\left(Z_m^n\right)=-\sum_{\substack{z_i\in Z_m\\ i=1.n}}p(z_1,\ldots,z_n)\log p(z_1,\ldots,z_n)$$

Усереднена ентропія на один символ n-грами дорівнює $H_n = \frac{H(Z_m^n)}{n}$. Для стаціонарних джерел існує границя цієї величини (у теорії інформації доводиться, що послідовність H_n є монотонно незростаючою).

Означення 5.8. Границя H_n при $n \to \infty$

$$H_\infty = \lim_{n\to\infty} H_n = \lim_{n\to\infty} \frac{H(Z_m^n)}{n}$$

називається *ентропією на символ джерела* і позначається H_∞ .

Моделі відкритого тексту.

Розглянемо, чому буде дорівнювати ентропія на символ джерела для різних моделей ВТ.

***Модель* M0.** У цій моделі джерело у кожен момент часу генерує символи із Z_m незалежно та рівноімовірно

$$P\left(x_i = z\right) = \frac{1}{m},\ z \in Z_m,\ i = 1, 2, \ldots;$$

Тоді $H(Z_m^n) = n \cdot H(Z_m) = n \cdot \log m$ (за властивістю ентропії) і ентропією на символ джерела

$$H_\infty = \frac{H(Z_m^n)}{n} = \log m.$$

***Модель* M1**. Символи тексту $x_1, x_2, \ldots, x_n, \ldots$ є незалежними, але вони генеруються із різними ймовірностями - з ймовірностями появи відповідного символу алфавіту в мові джерела послідовності

$$P\left(x_i = z\right) = p(z), i = 1, 2, \ldots\ ,\ z \in Z_m.$$

Внаслідок незалежності букв у тексті знаходимо

$$H_\infty = \lim_{n\to\infty} \frac{H(Z_m^n)}{n} = \lim_{n\to\infty} \frac{nH(Z_m)}{n} = H(Z_m) = -\sum_{z\in Z_m} p(z) \cdot \log p(z).$$

***Модель* M2.** Джерело генерує біграми $x_1x_2, x_3x_4, x_5x_6, \ldots$ і т.д. незалежно одну від одної. На множині Z_m^2 всіх біграм задано розподіл імовірностей $p(z_i, z_j), i, j = 1, \ldots, m$, і кожна нова біграма джерела генерується незалежно від інших.

Будемо розглядати тексти довжиною $2n$, $n \to \infty$. Оскільки біграми незалежні, то

$$H_\infty = \lim_{n\to\infty} \frac{H({Z_m}^{2n})}{2n} = \frac{nH(Z_m^2)}{2n} = \frac{H(Z_m^2)}{2} = H_2 .$$

***Модель* М3.** У цій моделі джерела ВТ послідовність $x_1, x_2, ...$ утворює однорідний ланцюг Маркова. Для завдання такого марковського ланцюга достатньо задати розподіл початкових станів $p_0(i), i \in Z_m$ та перехідні ймовірності $p_{ij} = \mathrm{P}(x_{n+1} = j / x_n = i), i, j \in Z_m$, які в силу однорідності не залежать від n.

Можна довести, що для джерела, що описується однорідним ланцюгом Маркова, який має стаціонарний розподіл $\{\pi_i\}$ та ймовірності переходу $p_{ij}, i, j \in Z_m$

$$H_\infty = -\sum_{i,j\in Z_m} \pi_i p_{ij} \log p_{ij} .$$

Величина H_n є n-м наближенням до H_∞. Зазначимо, що перші наближення H_1, H_2, H_3 ще дуже відрізняються від H_∞ (див. табл.5.1). В той же час обчислити H_n при великих значеннях n практично неможливо через величезну кількість можливих *n*-грам. З іншого боку, можна розглянути умовну ентропію n-го символу тексту при умові, що відомі $n-1$ попередніх символів: $H^{(n)} = H(x_n / x_1, ..., x_{n-1})$. В теорії інформації доводиться, що послідовність $H^{(n)}$ має границю при $n \to \infty$ і ця границя співпадає з границею послідовності H_n. Отже,

$$H_\infty = \lim_{n\to\infty} H(x_n / x_1, ..., x_{n-1}) .$$

Це є друге визначення ентропії на символ джерела. Воно використовується для експериментальної оцінки H_∞ шляхом вгадування носіями мови наступної букви тексту.

	H_0	H_1	H_2	H_3	H_5	H_8
Англійська мова	4.76	4.03	3.32	3.10	2.1	1.9
Російська мова	5	4.35	3.52	3.01	–	–

Табл. 5.1. Експериментальні оцінки H_n при деяких значеннях п.

Використовуючи друге визначення H_∞, А.Н.Колмогоров експериментально оцінив для російської мови $H^{(n)}$ при великих значеннях *n*. Виявилося, що після $H^{(30)}$ значення $H^{(n)}$ вже практично не змінюються, тобто дорівнюють H_∞, в той час як H_{15} ще відрізняється від H_∞. Аналогічні результати було отримано і для інших європейських мов (роботи К. Шеннона та ін.).

Надлишковість на символ джерела

Означення 5.9. *Надлишковістю на символ джерела* називається величина

$$R = 1 - \frac{H_\infty}{H_0},$$

де $H_0 = \log_2 m$ (m – кількість символів алфавіту). R називають також надлишковістю джерела.

Величина H_0 дорівнює максимальній кількості інформації, яку може нести в собі один символ джерела, а H_∞ – кількості інформації, яку насправді несе в собі один символ. Таким чином, для достатньо великих n величина $R \cdot n$ є середньою кількістю "зайвих" символів у тексті (джерела) довжиною n, після втрати яких теоретично можна відновити текст. Надлишковість текстів європейських мов знаходиться десь на рівні 60-80%. Але це не означає, що після випадкового видалення 60% символів (букв) завжди залишиться можливість відновити текст. Відкидати букви треба вибірково, використовуючи всі закономірності мови, і відновлювати також, використовуючи всі ці закономірності. Але практично врахувати всі закономірності неможливо. Експериментально встановлено: тільки до 25% букв можна видалити випадковим чином, щоб при цьому довільний текст залишився придатним для відновлення.

Якби букви в тексті були незалежними та рівномірно розподіленими, то H_∞ дорівнювало б H_0, а надлишковість R була б нульовою. Але тоді будь-яка послідовність букв була б змістовним текстом, і навіть найменша помилка при передачі призводила б до іншого змістовного тексту й не могла б бути визначена. При усному мовленні ми "ковтаємо" частину звуків, або виголошуємо їх нечітко, на письмі інколи робимо орфографічні помилки, та завдяки надлишковості мови все одно розуміємо один одного. Тож надлишковість – це природний механізм, що сприяє розумінню та протидіє помилкам.

Контрольні питання

1. Сформулюйте базові поняття математичної теорії інформації - поняття ймовірнісного ансамблю і ентропії (невизначеності) ймовірнісного ансамблю.
2. В яких одиницях вимірюється ентропія?
3. В яких межах може знаходитися ентропія ймовірнісного ансамблю?
4. Як задається сумісний ймовірнісний ансамбль з двох різних ймовірнісних ансамблів і як визначається сукупна ентропія сумісного ймовірнісного ансамблю?
5. Дайте означення незалежних ймовірнісних ансамблів.
6. Чому дорівнює сукупна ентропія незалежних ймовірнісних ансамблів?
7. Як визначається умовна ентропія одного ймовірнісного ансамблю відносно іншого ймовірнісного ансамблю в моделі сумісних ймовірнісних ансамблів?
8. Чи може умовна ентропія ймовірнісного ансамблю бути більше безумовною?
9. Яка величина називається взаємною інформацією ансамблів X та $У$?
10. Які теоретичні моделі відкритого тексту ви знаєте?
11. Поясніть визначення і зміст понять ентропії на символ джерела і надлишковісті джерела або текста.